

K-MEANS

MÉTHODE DES CENTRES MOBILES

PRÉSENTATION DU K-MEANS

- ✓ L'algorithme des K-moyennes est un algorithme qui permet de trouver des classes dans des données.
- ✓ les classes qu'il construit n'entretiennent jamais de relations hiérarchiques: une classe n'est jamais incluse dans une autre classe
- ✓ L'algorithme fonctionne en précisant le nombre de classes attendues.
- ✓ L'algorithme calcule les distances **Intra-Classe** et **Inter-Classe**.
- ✓ Il travaille sur des **variables continues**.

PRINCIPE ALGORITHMIQUE

Algorithme K-Means

Entrée : k le nombre de groupes cherchés

DEBUT

Choisir aléatoirement les centres des groupes

REPETER

- i. Affecter chaque cas au groupe dont il est le plus proche au son centre
- ii. Recalculer le centre de chaque groupe


JUSQU'À (stabilisation des **centres**)

OU (nombre d'itérations = **t**)


OU (stabilisation de **l'inertie totale** de la population)

FIN


SIMULATION DU K-MEANS 1




SIMULATION DU K-MEANS 2




SIMULATION DU K-MEANS 3




SIMULATION DU K-MEANS 4




SIMULATION DU K-MEANS 5



SIMULATION DU K-MEANS 6



SIMULATION DU K-MEANS 7



La méthode des k-moyennes (*K-Means*)

- L'algorithme *k-means* est en 4 étapes :
 1. Choisir k objets formant ainsi k clusters
 2. (Ré)affecter chaque objet O au cluster C_i de centre M_i tel que $\text{dist}(O, M_i)$ est minimal
 3. Recalculer M_i de chaque cluster (le barycentre)
 4. Aller à l'étape 2 si on vient de faire une affectation

K-Means :Exemple

- $A=\{1,2,3,6,7,8,13,15,17\}$. Créer 3 clusters à partir de A
- On prend 3 objets au hasard. Supposons que c'est 1, 2 et 3. Ça donne $C_1=\{1\}$, $M_1=1$, $C_2=\{2\}$, $M_2=2$, $C_3=\{3\}$ et $M_3=3$
- Chaque objet O est affecté au cluster au milieu duquel, O est le plus proche. 6 est affecté à C_3 car $\text{dist}(M_3,6) < \text{dist}(M_2,6)$ et $\text{dist}(M_3,6) < \text{dist}(M_1,6)$
On a $C_1=\{1\}$, $M_1=1$,
 $C_2=\{2\}$, $M_2=2$
 $C_3=\{3, 6, 7, 8, 13, 15, 17\}$, $M_3=69/7=9.86$

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas.
 $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$
- $\text{dist}(6, M_2) < \text{dist}(6, M_3) \rightarrow 6$ passe dans C_2 . Tous les autres objets ne bougent pas.
 $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3, 6\}$, $M_2 = 11/3 = 3.67$, $C_3 = \{7, 8, 13, 15, 17\}$, $M_3 = 12$
- $\text{dist}(2, M_1) < \text{dist}(2, M_2) \rightarrow 2$ passe en C_1 . $\text{dist}(7, M_2) < \text{dist}(7, M_3) \rightarrow 7$ passe en C_2 . Les autres ne bougent pas. $C_1 = \{1, 2\}$, $M_1 = 1.5$, $C_2 = \{3, 6, 7\}$, $M_2 = 5.34$, $C_3 = \{8, 13, 15, 17\}$, $M_3 = 13.25$
- $\text{dist}(3, M_1) < \text{dist}(3, M_2) \rightarrow 3$ passe en 1. $\text{dist}(8, M_2) < \text{dist}(8, M_3) \rightarrow 8$ passe en 2
 $C_1 = \{1, 2, 3\}$, $M_1 = 2$, $C_2 = \{6, 7, 8\}$, $M_2 = 7$, $C_3 = \{13, 15, 17\}$, $M_3 = 15$

Plus rien ne bouge

exercice

- Soit l'ensemble D des entiers suivants :
 $D = \{ 2, 5, 8, 10, 11, 18, 20 \}$
On veut répartir les données de D en trois (3) clusters, en utilisant l'algorithme Kmeans. La distance d entre deux nombres a et b est calculée ainsi :
- Appliquez Kmeans en choisissant comme centres initiaux des 3 clusters respectivement : 8, 10 et 11. Montrez toutes les étapes de calcul.

Exercice2

- Soit le tableau1 de 7 individus caractérisés par 2 variables. Tab.1
- On souhaite construire deux groupes homogènes à partir de ces individus.
- On propose de commencer la construction à partir des deux groupes du tableau 2.
- Continuer la construction des groupes en utilisant la distance euclidienne pour mesurer la similarité entre individus.

Subject	A	B
1	1.0	1.0
2	1.5	2.0
3	3.0	4.0
4	5.0	7.0
5	3.5	5.0
6	4.5	5.0
7	3.5	4.5

Tab.1

	Individual	Mean Vector (centroid)
Group 1	1	(1.0, 1.0)
Group 2	4	(5.0, 7.0)

Tab.2

$$d(i,j) = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2 + \dots + (x_{ip} - x_{jp})^2}$$

POINTS FAIBLES DE K-MEANS

- Le choix du nombre de groupes est subjectif dans le cas où le nombre de classes est inconnu au sein de l'échantillon.
- L'algorithme du K-Means ne trouve pas nécessairement la configuration la plus optimale correspondant à la fonction objective minimale.
- Les résultats de l'algorithme du K-Means sont sensibles à l'initialisation aléatoires des centres.